

Examen Travaux Pratiques			
 جامعة تونس الافتراضية UNIVERSITÉ VIRTUELLE DE TUNIS	Matière	ATELIER SPARK	
	Enseignants	H. Hmida	
	Classes	BADS1	
		Date	25/05/2025
		Durée	01h30
		Doc. Autorisés	OUI
		Calculat. Autorisée	NON
		Nombre de pages	2

Note importante :

Créer un **Notebook** portant vos **noms et prénoms**. Le Notebook sera déposé sur l'espace de cours Moodle. Il doit comporter la **trace d'exécution**.

Partie 1 : SparkSQL (14 pts)

Télécharger les données relatives aux résultats de Formule 1 pour les saisons de 2020 jusqu'à 2023 à partir de ce lien : <https://tinyurl.com/f1-data>

Les données sont réparties sur les fichiers csv :

- `racess.csv` : contenant les Grand Prix disputés chaque saison.
- `results.csv` : le résultat de chaque Grand Prix.

(Voir la description des colonnes en annexe)

1. Charger les fichiers dans des DataFrames Spark appelés respectivement **racess_df** et **results_df**.
2. Ajouter une colonne « GP » au DataFrame **racess_df** contiendra le nom du Grand Prix extrait à partir de la colonne « url ». Par exemple : de l'url http://en.wikipedia.org/wiki/2020_Austrian_Grand_Prix on extrait le nom « Austrian Grand Prix ».
3. Trouver le pilote et le constructeur qui ont remporté les 2 dernières éditions du Grand Prix « Spanish Grand Prix ».
4. Trouver le nombre de podiums (1^{ère}, 2^{ème} et 3^{ème} place) par constructeur et par saison.
5. Trouver le pilote qui a remporté le plus de Grand Prix (1^{ère} place).
6. Trouver le pilote ayant la plus longue série de victoires consécutives (round).

Partie 2 : SparkStream (6 pts)

7. En utilisant le code fourni créer des fichiers csv contenant les résultats des 3 premières courses de la saison 2020. (Vérifier la création de 3 fichiers `2020_1.csv` ... `2020_3.csv`)

```
for r in range(1,4):
    d = results_df.where("round="+str(r)+" and season=2020").toPandas()
    d.to_csv("2020_"+str(r)+".csv", index=False)
```

8. Nous voulons calculer le classement des pilotes en continu suite à chaque étape de la saison. Spark attend les résultats dans un dossier **f1_stream** (à créer). Suite

à la copie d'un fichier CSV (par exemple 2020_1.csv), le classement affiche le rang, nom du pilote, et le total des points obtenus.

9. Calculer en continu le nombre moyen de points gagnés dans les 2 dernières courses.

Description des colonnes :

season	Année	driver	Nom du pilote
round	Numéro de course	constructor	Équipe F1
circuit_id	Nom du circuit	date_of_birth	Date de naissance
lat	Position du circuit	nationality	Nationalité
long	Position du circuit	grid	Position au départ de la course
country	Pays	time	Temps de la course
date	Date	points	Points gagnés par le pilote
url	Adresse URL	status	Le pilote a-t-il fini ou non la course
podium	Position finale du pilote		